

Steam Yorumları

Uçtan uca büyük veri pipeline'ı ve makine öğrenmesi
tabanlı duygu analizi



”Bir oyun gerçekten *iyi* mi?”

Steam platformunda milyonlarca kullanıcı oyunları metin yorumlarıyla değerlendiriyor. Bu yorumlar, oyun deneyiminin en doğrudan sinyalini taşıyor — ancak insan eliyle okunamayacak ölçekte.

Otomatik duygu analizi; oyun geliştiricilere, mağaza editörlerine ve platforma **ölçeklenebilir ve anlık geri bildirim** sağlar. Bu proje, bu geri bildirimi üreten uçtan uca büyük veri pipeline'ını kurar.

STREAMİNG

VERİ GÖLÜ

MAKİNE ÖĞRENMESİ

GÖRSELLEŞTİRME



STEAM YORUMU (KAGGLE)

~21 Milyon



BENZERSİZ OYUN

5.580



GÖREV TİPİ

Binary Sınıflandırma

Pozitif ● vs Negatif ●

Steam Reviews Dataset

KAYNAK


Kaggle • Public Dataset

Boyut 2.06 GB • CSV
Satır Sayısı 5.000.000
Sütun Sayısı 8
Format UTF-8, virgül ayrıklı

ALANLAR

event_id app_id app_name review_text review_score review_votes
timestamp event_type

SINIF DAĞILIMI



4.067.557 pozitif


932.443 negatif

Belirgin sınıf dengesizliği —
eğitimde undersampling ile
dengendi.

EN ÇOK YORUMLANAN OYUNLAR

PAYDAY 2		88.973
DayZ		88.850
Team Fortress 2		71.457
Garry's Mod		55.120

Uçtan Uca Pipeline Mimarisi



ORKESTRASYON

Docker
Compose

5 servis · tek komut

SERVISLER

- ▶ Zookeeper
- ▶ Kafka Broker
- ▶ Python Producer
- ▶ Spark Streaming
- ▶ Dashboard

MİMARİ NOTU

Medallion mimarisi
(Bronze / Silver / Gold) —
Gold katmanı bu projede
training script'lerine
gömüldü.

Docker Compose + Kafka

Konteynerizasyon

docker-compose.yml • 5 servis

SERVİS	KONTEYNER ADI
Zookeeper	steam_zookeeper
Kafka Broker	steam_kafka
Python Producer	steam_review_producer
Spark Streaming	steam_spark_streaming
Dashboard	steam_dashboard

```
# tek komutla ayağa kalkar
$ docker compose up -d --build
```

Streaming Simülasyonu

producer → kafka topic: steam_reviews

5.000.000

KAFKA'YA GÖNDERİLEN MESAJ

JSON

HER MESAJDA 8 ALAN

0.0 sn

MESSAGE_DELAY_SECONDS

timestamp • event_id • app_id • app_name
review_text • review_score • review_votes • event_type

Spark Structured Streaming → Delta Lake

Medallion mimarisi: ham veriyi koruyarak temizlenmiş, sorgulanabilir bir katman üretir.

BRONZE LAYER • ● HAM

Dönüşümsüz Ham Kayıt

- ▶ Kafka'dan gelen tüm mesajlar 1:1 yazılır
- ▶ Hiçbir filtre, hiçbir dönüşüm uygulanmaz
- ▶ Hata durumunda kaynak referans noktası

HEDEF KONUM

```
data/delta/bronze/steam_reviews_raw
```

SILVER LAYER • ◆ TEMİZ

Temizlenmiş, Tipli, Türetilmiş

- ✓ Null filtresi: review_text, app_name
- ✓ Sentiment türetme: `score=1 → "positive"` · `-1 → "negative"`
- ✓ event_time TIMESTAMP olarak eklendi


5.000.000 SILVER SATIRI

```
data/delta/silver/steam_reviews_clean
```

⚠ **Gold katmanı yok:** Özellik mühendisliği training script'lerine gömüldü — Slayt 12'de tartışılan sınırlamalardan biri.

EDA Bulguları — 5M Satır Üzerinde

01 • SINIF DENGESİZLİĞİ



4.067.557 pozitif

932.443 negatif

Modelde her sınıftan **25.000 örnek** undersampling.

02 • YORUM UZUNLUĞU

NEGATİF



ort. 388 kr

POZİTİF



ort. 291 kr

+%33 — Mutsuz kullanıcılar daha uzun yazıyor.

03 • EN ÇOK YORUMLANAN OYUNLAR

PAYDAY 2		88.973
DayZ		88.850
Team Fortress 2		71.457
Dota 2		63.241
Garry's Mod		55.120

04 • VERİ KALİTESİ



0

EKSİK DEĞER

Silver katman null filtresi tüm kolonlarda başarılı — temiz hat.

TF-IDF Tabanlı **Metin İşleme** Pipeline'ı

SPARK ML PIPELINE AŞAMALARI

StringIndexer

→

Tokenizer

→

StopWordsRemover

→

CountVectorizer

→

IDF

→

Classifier

4 MODEL (DT • RF • GBT • NB)

CountVectorizer

vocabSize 5.000
minDF 5
Vektör boyut 5.000
Eğitim/sınıf 25.000 örnek

Frekansa göre top-5.000 token. Tarihsel, Spark ile uyumlu, açıklanabilir.

LOGİSTİK REGRESSION

HashingTF

numFeatures 20.000
Vektör boyut 20.000
Eğitim/sınıf 100.000 örnek
Hashing açık
trick

Daha geniş özellik uzayı + daha fazla eğitim verisi. Slayt 12'de tartışılır.

⚠ **Yalnızca metin özellikleri kullanıldı.** review_text_length, review_votes, app_review_count gibi sayısal sinyaller modele dahil edilmedi — gelecek çalışma.

5 Model • MLflow ile Karşılaştırmalı Değerlendirme

★ BEST

Logistic Regression

AUC

0.9424

Accuracy

0.8795

— BASELINE

Naive Bayes

AUC

0.5723

Accuracy

0.8333

— EMSEMBLE

Gradient Boosted Trees

AUC

0.8187

Accuracy

0.7341

— EMSEMBLE

Random Forest

AUC

0.8014

Accuracy

0.7107

— TREE

Decision Tree

AUC

0.5157

Accuracy

0.6114

MODEL	ACCURACY	F1	PRECISION	RECALL	AUC-ROC
★ Logistic Regression	0.8795	0.8794	0.8797	0.8795	0.9424
Naive Bayes	0.8333	0.8333	0.8334	0.8333	0.5723
Gradient Boosted Trees	0.7341	0.7319	0.7414	0.7341	0.8187
Random Forest	0.7107	0.7029	0.7367	0.7107	0.8014
Decision Tree	0.6114	0.5691	0.6807	0.6114	0.5157

Logistic Regression • Derinlemesine

İki sınıf arasında dengeli hata, AUC=0.9424 ile rastlantısal sınıflandırıcıyı belirgin biçimde geçer.

CONFUSION MATRIX

	TAHMİN: POS	TAHMİN: NEG
GERÇEK: POS	TP 16.596	FN 3.325
GERÇEK: NEG	FP 3.178	TN 16.921

Toplam test: 40.020 örnek • Dengelenmiş hata dağılımı.

METRİKLER

0.9424

AUC-ROC

0.8795

ACCURACY

0.833

SENSITIVITY

0.8794


F1 SCORE

0.842

SPECIFICITY

Sensitivity $\approx$ Specificity $\rightarrow$ iki sınıfta da benzer performans.

ROC CURVE



FPR

ALAN ALTI

0.9424

RASTLANTISAL

0.5000

Fark: +0.4424

Streamlit Dashboard — localhost:8501

PIPELINE ENTEGRASYONU

```
# Docker servisi olarak çalışır
$ docker compose up -d \
  --build dashboard
```

5 sayfalı interaktif dashboard, MLflow file-store ve Delta katmanları üzerinden veri okur.

TEKNOLOJİ STACK

Streamlit

Plotly

PyArrow

scikit-learn

pandas

ERİŞİM

<http://localhost:8501>

Landing

Pipeline özeti, 4 metrik kartı, sistem durumu



EDA

10 bölüm • sentiment, trend, top-app grafikleri



Features

TF-IDF pipeline • top-20 kelime grafikleri



Model Comparison

5 model grouped bar + karşılaştırma tablosu



Best Model

Confusion Matrix • ROC Curve • Feature Importance

✓ Hedef Tamamlandı

- ✓ Uçtan uca pipeline: Kafka → Spark → Delta Lake → ML → Dashboard
- ✓ 5.000.000 yorum işlendi, Bronze + Silver katmanlar oluşturuldu
- ✓ 5 model eğitildi ve MLflow ile karşılaştırmalı takip edildi
- ✓ Streamlit dashboard Docker servisi olarak yayında

EN İYİ MODEL

Logistic Regression

0.9424 AUC-ROC

→ Sonraki Adımlar

- Sayısal özellikler ekle: `review_votes, text_length, app_review_count`
- Gold Delta katmanı oluştur — özellik mühendisliğini script'lerden ayır
- Stratified split + hyperparameter grid search uygula
- Tüm modelleri eşit koşullarda yeniden karşılaştır
- Orijinal timestamp ile gerçek zaman serisi analizi

TEKRARLANABİLİR

MODÜLER

DOCKER COMPOSE

GENİŞLETİLEBİLİR

SUNUM SONU

Teşekkürler

Sorularınız?

STEAM YORUMLARI • BÜYÜK VERİ PIPELINE'I • 2025-2026 BAHAR