

01 • BÜYÜK VERİ ANALİZİNE GİRİŞ • 2025-2026 BAHAR • DR. AYŞE GÜL EKER

DÖNEM PROJESİ • SUNUM

Steam Yorumları

Uçtan uca büyük veri pipeline'ı ve makine öğrenmesi tabanlı duygu analizi



KAPAK

github.com/steam-reviews-pipeline

02 • MOTİVASYON

PROBLEM TANIMI

”Bir oyun gerçekten iyi mi?”

Steam platformunda milyonlarca kullanıcı oyunları metin yorumlarıyla değerlendiriyor. Bu yorumlar, oyun deneyiminin en doğrudan sinyalini taşıyor — ancak insan eliyle okunamayacak ölçekte.

Otomatik duygu analizi; oyun geliştiricilere, mağaza editörlerine ve platforma **ölçeklenebilir ve anlık geri bildirim** sağlar. Bu proje, bu geri bildirimi üreten uçtan uca büyük veri pipeline'ını kurar.

STREAMING

VERİ GÖLÜ

MAKİNE ÖĞRENMESİ

GÖRSELLEŞTİRME

 STEAM YORUMU (KAGGLE)

~21 Milyon

 BENZERSİZ OYUN

5.580

 GÖREV TİPİ

Binary Sınıflandırma

Pozitif • vs Negatif •

03 • VERİ SETİ

Steam Reviews Dataset

KAYNAK

Kaggle • Public Dataset

Boyut 2.06 GB • CSV

Satır Sayısı 5.000.000

Sütun Sayısı 8

Format UTF-8, virgül ayrıçlı

ALANLAR

event_id	app_id	app_name	review_text	review_score	review_votes
timestamp	event_type				

SINIF DAĞILIMI



4.067.557 pozitif

932.443 negatif

Belirgin sınıf dengesizliği —
eğitimde undersampling ile
dengелendi.

EN ÇOK YORUMLANAN OYUNLAR

PAYDAY 2	88.973
DayZ	88.850
Team Fortress 2	71.457
Garry's Mod	55.120

VERİ SETİ

03 / 13

04 • SİSTEM MİMARİSİ

Uçtan Uca Pipeline Mimarisi



Docker Compose + Kafka

Konteynerizasyon

docker-compose.yml • 5 servis

SERVİS	KONTYNER ADI
Zookeeper	steam_zookeeper
Kafka Broker	steam_kafka
Python Producer	steam_review_producer
Spark Streaming	steam_spark_streaming
Dashboard	steam_dashboard

```
# tek komutla ayağa kalkan  
$ docker compose up -d --build
```

⚡ Streaming Simülasyonu

producer → kafka topic: steam_reviews

5.000.000

KAFKA'YA GÖNDERİLEN MESAJ

JSON

HER MESAJDA 8 ALAN

0.0 sn

MESSAGE_DELAY_SECONDS

timestamp • event_id • app_id • app_name
review_text • review_score • review_votes • event_type

06 • SPARK • DELTA LAKE

Spark Structured Streaming → Delta Lake

Medallion mimarisi: ham veriyi koruyarak temizlenmiş, sorgulanabilir bir katman üretir.

BRONZE LAYER • HAM

Dönüşümsüz Ham Kayıt

- ▶ Kafka'dan gelen tüm mesajlar 1:1 yazılır
- ▶ Hiçbir filtre, hiçbir dönüşüm uygulanmaz
- ▶ Hata durumunda kaynak referans noktası

HEDEF KONUSU

`data/delta/bronze/steam_reviews_raw`

SILVER LAYER • TEMİZ

Temizlenmiş, Tipli, Türetilmiş

- ✓ Null filtresi: review_text, app_name
- ✓ Sentiment türetme: `score=1 → "positive"` · `-1 → "negative"`
- ✓ event_time TIMESTAMP olarak eklendi

5.000.000

SILVER SATIRI

`data/delta/silver/steam_reviews_clean`

⚠ **Gold katmanı yok:** Özellik mühendisliği training script'lerine gömüldü — Slayt 12'de tartışılan sınırlamalardan biri.

SPARK • DELTA LAKE

06 / 13

07 • KEŞİFSEL VERİ ANALİZİ

EDA Bulguları — 5M Satır Üzerinde

01 • SINIF DENGESİZLİĞİ



4.067.557 pozitif
932.443 negatif

Modelde her sınıftan 25.000 örnek undersampling.

02 • YORUM UZUNLUĞU




+%33 — Mutsuz kullanıcılar daha uzun yazıyor.

03 • EN ÇOK YORUMLANAN OYUNLAR



04 • VERİ KALİTESİ



TF-IDF Tabanlı Metin İşleme Pipeline'i

SPARK ML PIPELINE AŞAMALARI



4 MODEL (DT • RF • GBT • NB)

CountVectorizer

vocabSize 5.000
minDF 5
Vektör boyut 5.000
Eğitim/sınıf 25.000 örnek

Frekansa göre top-5.000 token. Tarihsel, Spark ile uyumlu, açıklanabilir.

LOGISTIC REGRESSION

HashingTF

numFeatures 20.000
Vektör boyut 20.000
Eğitim/sınıf 100.000 örnek
Hashing açık
trick

Daha geniş özelliklik uzayı + daha fazla eğitim verisi. Slayt 12'de tartışılır.

⚠ **Yalnızca metin özelliklikleri kullanıldı.** review_text_length, review_votes, app_review_count gibi sayısal sinyaller modele dahil edilmedi — gelecek çalışma.

5 Model • MLflow ile Karşılaştırmalı Değerlendirme

★ BEST Logistic Regression AUC 0.9424 Accuracy 0.8795	— BASELINE Naive Bayes AUC 0.5723 Accuracy 0.8333	— ENSEMBLE Gradient Boosted Trees AUC 0.8187 Accuracy 0.7341	— ENSEMBLE Random Forest AUC 0.8014 Accuracy 0.7107	— TREE Decision Tree AUC 0.5157 Accuracy 0.6114
--	--	---	--	--

MODEL	ACCURACY	F1	PRECISION	RECALL	AUC-ROC
★ Logistic Regression	0.8795	0.8794	0.8797	0.8795	0.9424
Naive Bayes	0.8333	0.8333	0.8334	0.8333	0.5723
Gradient Boosted Trees	0.7341	0.7319	0.7414	0.7341	0.8187
Random Forest	0.7107	0.7029	0.7367	0.7107	0.8014
Decision Tree	0.6114	0.5691	0.6807	0.6114	0.5157

10 • EN İYİ MODEL • DERİN ANALİZ

Logistic Regression • Derinlemesine

İki sınıf arasında dengeli hata, AUC=0.9424 ile rastlantısal sınıflandırıcıyı belirgin biçimde geçer.

CONFUSION MATRIX

TAHHİN: POS

TAHHİN: NEG

GERÇEK: POS

GERÇEK: NEG

TP

16.596

FP

3.178

FN

3.325

TN

16.921

Toplam test: 40.020 örnek • Dengelenmiş hata dağılımı.

METRİKLER

0.9424

AUC-ROC

0.8795

ACCURACY

0.833

SENSITIVITY

0.8794


F1 SCORE

0.842

SPECIFICITY

Sensitivity $\approx$ Specificity $\rightarrow$ İki sınıfta da benzer performans.

ROC CURVE



FPR

ALAN ALTI

0.9424

RASTLANTISAL

0.5000

Fark: +0.4424

EN İYİ MODEL • LOGİSTİK REGRESİYON

10 / 13

Streamlit Dashboard — localhost:8501

PIPELINE ENTEGRASYONU

```
# Docker servisi olarak çalışır
$ docker compose up -d \
  --build dashboard
```

5 sayfalı interaktif dashboard, MLflow file-store ve Delta katmanları üzerinden veri okur.

TEKNOLOJİ STACK

Streamlit Plotly PyArrow scikit-learn pandas

ERİŞİM

<http://localhost:8501>



Landing

Pipeline özeti, 4 metrik kartı, sistem durumu



EDA

10 bölüm · sentiment, trend, top-app grafikleri



Features

TF-IDF pipeline · top-20 kelime grafikleri



Model Comparison

5 model grouped bar + karşılaştırma tablosu



Best Model

Confusion Matrix · ROC Curve · Feature Importance

12 • SONUÇ • İLERİ ÇALIŞMA
TAMAMLANANLAR

✓ Hedef Tamamlandı

- ✓ Uçtan uca pipeline: Kafka → Spark → Delta Lake → ML → Dashboard
- ✓ 5.000.000 yorum işlendi, Bronze + Silver katmanlar oluşturuldu
- ✓ 5 model eğitildi ve MLflow ile karşılaştırmalı takip edildi
- ✓ Streamlit dashboard Docker servisi olarak yayında

EN İYİ MODEL

Logistic Regression

0.9424 AUC-ROC

GELECEK ÇALIŞMA

→ Sonraki Adımlar

- Sayısal özellikler ekle: review_votes, text_length, app_review_count
- Gold Delta katmanı oluşturun — özellik mühendisliğini script'lerden ayırın
- Stratified split + hyperparameter grid search uygulayın
- Tüm modelleri eşit koşullarda yeniden karşılaştırın
- Orijinal timestamp ile gerçek zaman serisi analizi

TEKRARLANABİLİR

MODÜLER

DOCKER COMPOSE

GENİŞLETİLEBİLİR

SONUÇ • İLERİ ÇALIŞMA

12 / 13

13 • KAPANIŞ

SUNUM SONU

Teşekkürler

Sorularınız?

STEAM YORUMLARI • BÜYÜK VERİ PIPELINE'I • 2025-2026 BAHAR

MAYIS 2026

github.com/steam-reviews-pipeline